METODOLOGIA

Como vamos ouvir o gol

1
Áudio
Transmissão da partida, mono, 16 kHz

→

2
Preparo do sinal
Filtro na faixa da voz (300–3400 Hz) e corte em janelas de poucos segundos

→

3
Representação
Volume e tom → mel-espectrograma → *embeddings* de rede neural

→

4
Modelo
Dá a cada janela uma nota de "é lance?"

Níveis 0 → 3 · próximo slide

→

5
Lances no tempo
Suaviza, aplica limiar e junta picos vizinhos → minuto do lance

→

6
Validação
Acerto se cair a ±T do gabarito: precisão, revocação, F1

DADOS **Treino** **SoccerNet** jogos anotados → **Validação** **SoccerNet** outros jogos → **Teste** **CazéTV** trechos da Copa 2026

Só o **bloco 4** muda de um nível para o outro. Áudio, janelas e avaliação continuam iguais, então a comparação entre os modelos é justa.

METODOLOGIA · MODELOS

Do mais simples ao mais complexo

NÍVEL 0 · BASELINE

Regras sobre a voz

Volume (RMS) + tom (F0)

Limiar no grito: alto, agudo e sustentado por ≥ 2 s

✓ feito · revocação de gols 0,61–0,74

[1] [3]

NÍVEL 1 · ML CLÁSSICO

Atributos + classificador

MFCC, RMS, F0, centróide espectral

Regressão logística ou Random Forest aprendem os pesos que hoje escolhemos à mão

[2]

NÍVEL 2 · DEEP LEARNING

CNN pré-treinada

Mel-espectrograma

Embeddings VGGish ou PANNs, treinadas em milhões de áudios do AudioSet, mais um classificador leve por janela

[5] [6] [7]

NÍVEL 3 · ESTADO DA ARTE

Transformer auto-supervisionado

Mel-espectrograma ou onda bruta

AST ou wav2vec 2.0 com *fine-tuning* para a excitação da fala, olhando o que vem antes e depois do lance

[8] [9] [10]

regras fixas · poucos dados · CPU → aprendido · mais dados · GPU

Cada nível só avança se superar o anterior em F1 na mesma validação do SoccerNet [4].

[1] Rui, Gupta, Acero. Automatically extracting highlights for TV baseball programs. ACM Multimedia, 2000.
[2] Xiong et al. Audio events detection based highlights extraction from baseball, golf and soccer games in a unified framework. IEEE ICME, 2003.
[3] Mauch, Dixon. pYIN: a fundamental frequency estimator using probabilistic threshold distributions. IEEE ICASSP, 2014.
[4] Giancola et al. SoccerNet: a scalable dataset for action spotting in soccer videos. CVPR Workshops, 2018.
[5] Hershey et al. CNN architectures for large-scale audio classification. IEEE ICASSP, 2017.
[6] Kong et al. PANNs: large-scale pretrained audio neural networks for audio pattern recognition. IEEE/ACM TASLP, 2020.
[7] Vanderplaetse, Dupont. Improved soccer action spotting using both audio and video streams. CVPR Workshops, 2020.
[8] Gong, Chung, Glass. AST: Audio Spectrogram Transformer. Interspeech, 2021.
[9] Baevski et al. wav2vec 2.0: a framework for self-supervised learning of speech representations. NeurIPS, 2020.
[10] Giancola, Ghanem. Temporally-aware feature pooling for action spotting in soccer broadcasts. CVPR Workshops, 2021.