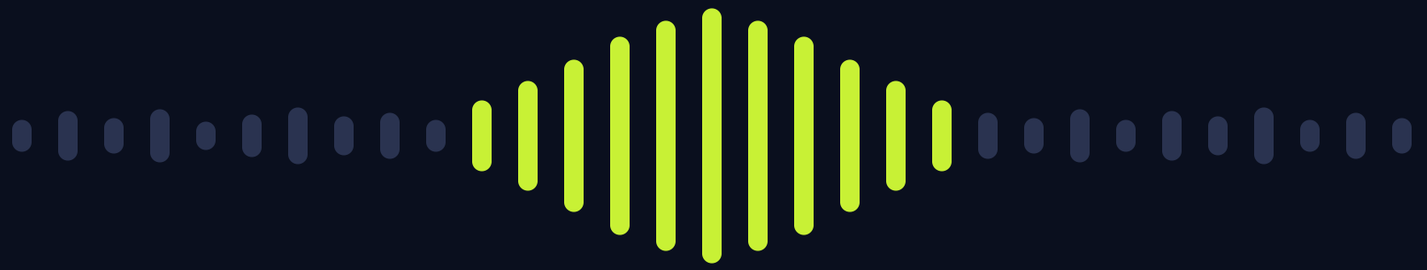
EQUIPE OUVINDO O GOL · PRÉVIA DO SEMINÁRIO

Ouvindo o gol

A voz do narrador como atalho para os melhores momentos de uma partida



Felipe Orlow, Pedro Augusto, Murilo Uchôa e Gustavo Barros

INF0413 · Signal and Image Processing · 06/11/2026

MOTIVAÇÃO · O PROBLEMA

Muito jogo, poucos lances que importam

90 min → **≈ 26**

5.400 segundos de transmissão

lances-chave por jogo

Nos 12 jogos do SoccerNet que analisamos: **310 lances-chave** (gols, pênaltis, finalizações e expulsões), **55 deles gols**. Hoje, achar esses lances é **trabalho manual**: alguém assiste ao jogo inteiro, anota e recorta.

Fonte: anotações do SoccerNet, 12 jogos (24 tempos) usados no trabalho

O narrador já assistiu ao jogo inteiro por nós.

Ele reage a cada lance em tempo real. Quando algo importa, a voz muda: fica mais alta, mais aguda e se sustenta. Esse é o sinal que vamos ouvir.

Volume **Tom** **Duração**

POR QUE ÁUDIO

≈ 400×

menos números por segundo que o vídeo. E a narração está em toda transmissão, até no rádio.



CONTEXTO

O que a literatura já fez

2000–2003

Highlights pelo áudio

A empolgação do narrador já indicava os melhores lances no beisebol, golfe e futebol.

[1] [2]

2017–2021

Redes que “ouvem”

Modelos pré-treinados em milhões de áudios: VGGish, PANNs, AST e wav2vec 2.0.

[5] [6] [8] [9]

2018

SoccerNet

500 jogos com lances anotados viram a referência para *action spotting* no futebol.

[4]

2020–2021

Áudio no futebol

Somar o áudio ao vídeo melhora o *spotting* no SoccerNet; o contexto temporal ajuda.

[7] [10]

ONDE ENTRAMOS **Só a voz do narrador**, sem vídeo: comparar regras simples e redes neurais no mesmo pipeline.

METODOLOGIA · PIPELINE

Como vamos ouvir o gol

1
Áudio
Transmissão da partida, mono, 16 kHz

→

2
Preparo do sinal
Filtro na faixa da voz (300–3400 Hz) e corte em janelas de poucos segundos

→

3
Representação
Volume e tom → mel-espectrograma → *embeddings* de rede neural

→

4
Modelo
Dá a cada janela uma nota de "é lance?"

Níveis 0 → 3 · próximo slide

→

5
Lances no tempo
Suaviza, aplica limiar e junta picos vizinhos → minuto do lance

→

6
Validação
Acerto se cair a ±T do gabarito: precisão, revocação, F1

DADOS **Treino** **SoccerNet** jogos anotados → **Validação** **SoccerNet** outros jogos → **Teste** **CazéTV** trechos da Copa 2026

Só o **bloco 4** muda de um nível para o outro. Áudio, janelas e avaliação continuam iguais, então a comparação entre os modelos é justa.

METODOLOGIA · MODELOS

Do mais simples ao mais complexo

NÍVEL 0 · BASELINE

Regras sobre a voz

Volume (RMS) + tom (F0)

Limiar no grito: alto, agudo e sustentado por ≥ 2 s

✓ feito · revocação de gols 0,61–0,74

[1] [3]

NÍVEL 1 · ML CLÁSSICO

Atributos + classificador

MFCC, RMS, F0, centróide espectral

Regressão logística ou Random Forest aprendem os pesos que hoje escolhemos à mão

[2]

NÍVEL 2 · DEEP LEARNING

CNN pré-treinada

Mel-espectrograma

Embeddings VGGish ou PANNs, treinadas em milhões de áudios do AudioSet, mais um classificador leve por janela

[5] [6] [7]

NÍVEL 3 · ESTADO DA ARTE

Transformer auto-supervisionado

Mel-espectrograma ou onda bruta

AST ou wav2vec 2.0 com *fine-tuning* para a excitação da fala, olhando o que vem antes e depois do lance

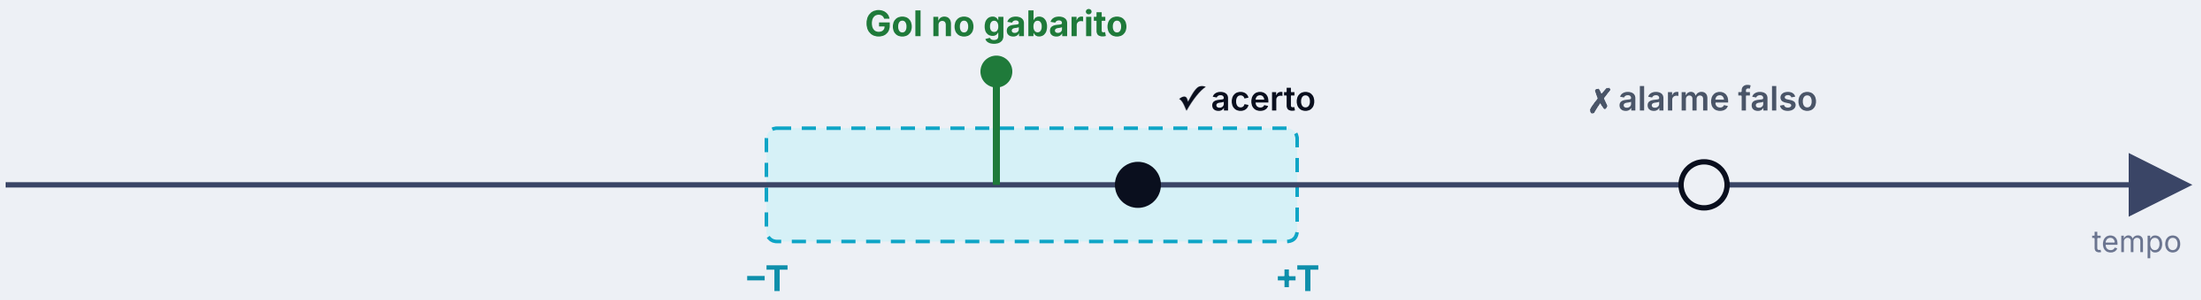
[8] [9] [10]

regras fixas · poucos dados · CPU → aprendido · mais dados · GPU

Cada nível só avança se superar o anterior em F1 na mesma validação do SoccerNet [4].

METODOLOGIA · VALIDAÇÃO

Como medir o sucesso



Precisão

Dos lances que achamos, quantos eram reais

Revocação

Dos lances reais, quantos achamos

F1

Equilíbrio entre as duas: é a nota que decide se um nível avança

Validação em **jogos do SoccerNet separados do treino** e teste final em **trechos da CazéTV** que nenhum modelo viu: outro narrador, outra língua, outra transmissão.

CRONOGRAMA

Seis semanas até a entrega final

HOJE

SEMANA 1

06/11

Prévia

- Revisão da literatura
- Ampliar a base SoccerNet
- Rotular janelas de áudio

SEMANA 2

13/11

Checkpoint 1

- Proposta
- Nível 0 medido em toda a validação

SEMANA 3

20/11

Nível 1

- MFCC e atributos espectrais
- Random Forest / regressão logística

SEMANA 4

27/11

Nível 2

- *Embeddings* PANNs / VGGish
- Classificador por janela

SEMANA 5

04/12

Nível 3

- AST / wav2vec 2.0 com *fine-tuning* (GPU Colab)
- Teste na CazéTV

SEMANA 6

11/12

Apresentação final

- Comparação dos 4 níveis
- Clipes automáticos dos melhores momentos

Referências

[1] Y. Rui, A. Gupta, A. Acero. *Automatically extracting highlights for TV baseball programs.* ACM Multimedia, 2000.

[2] Z. Xiong et al. *Audio events detection based highlights extraction from baseball, golf and soccer games in a unified framework.* IEEE ICME, 2003.

[3] M. Mauch, S. Dixon. *pYIN: a fundamental frequency estimator using probabilistic threshold distributions.* IEEE ICASSP, 2014.

[4] S. Giancola et al. *SoccerNet: a scalable dataset for action spotting in soccer videos.* CVPR Workshops, 2018.

[5] S. Hershey et al. *CNN architectures for large-scale audio classification.* IEEE ICASSP, 2017.

[6] Q. Kong et al. *PANNs: large-scale pretrained audio neural networks for audio pattern recognition.* IEEE/ACM TASLP, 2020.

[7] B. Vanderplaetse, S. Dupont. *Improved soccer action spotting using both audio and video streams.* CVPR Workshops, 2020.

[8] Y. Gong, Y.-A. Chung, J. Glass. *AST: Audio Spectrogram Transformer.* Interspeech, 2021.

[9] A. Baevski et al. *wav2vec 2.0: a framework for self-supervised learning of speech representations.* NeurIPS, 2020.

[10] S. Giancola, B. Ghanem. *Temporally-aware feature pooling for action spotting in soccer broadcasts.* CVPR Workshops, 2021.



Obrigado!

Perguntas? · Equipe Ouvindo o Gol